SY09 Printemps 2020
TP 0 — Introduction à NumPy et Pandas

1 Introduction à NumPy

NumPy est une bibliothèque pour la calcul numérique en Python. Pour charger la bibliothèque, il suffit d'exécuter l'instruction suivante :

```
In  [1]: import numpy as np
```

Tableaux unidimensionnels

Création

Des tableaux unidimensionnels peuvent être créés à partir d'une simple liste Python.

```
In  [2]: a = np.array([1, 2, 3])
         b = np.array(range(4))
```

Il existe des fonctions prédéfinies pour créer rapidement des séquences.

```
In  [3]: np.arange(10)
Out [3]: array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])
In  [4]: np.linspace(0, 5, 10)
Out [4]: array([0.        , 0.55555556, 1.11111111, 1.66666667, 2.22222222,
         ↪  2.77777778, 3.33333333, 3.88888889, 4.44444444, 5.        ])
In  [5]: np.logspace(0, 2, 5)
Out [5]: array([  1.        ,   3.16227766,  10.        ,  31.6227766 , 100.
         ↪  ])
In  [6]: np.geomspace(0.1, 100, 4)
Out [6]: array([  0.1,   1. ,  10. , 100. ])
```

(1) Définir les tableaux suivants :
- $t_1 = \left(1, 10, 100, \ldots, 10^{10}\right)$
- $t_2 = (0, 2, 4, \ldots, 100)$
- $t_3 = (0, -1, -2, \ldots, -10)$

On peut également spécifier la longueur et la valeur d'initialisation.

```
In  [7]: c = np.zeros(4)
         d = np.ones(3)
         e = np.full(5, 3.8)
```

Ou alors spécifier la valeur d'initialisation et la taille d'un autre tableau.

```
In  [8]: f = np.zeros_like(d)
         g = np.ones_like(e)
```

On peut également créer des tableaux suivant une loi

```
In [9]: h = np.random.normal(loc=3, scale=2, size=1000)
        plt.hist(h)
        plt.show()
```

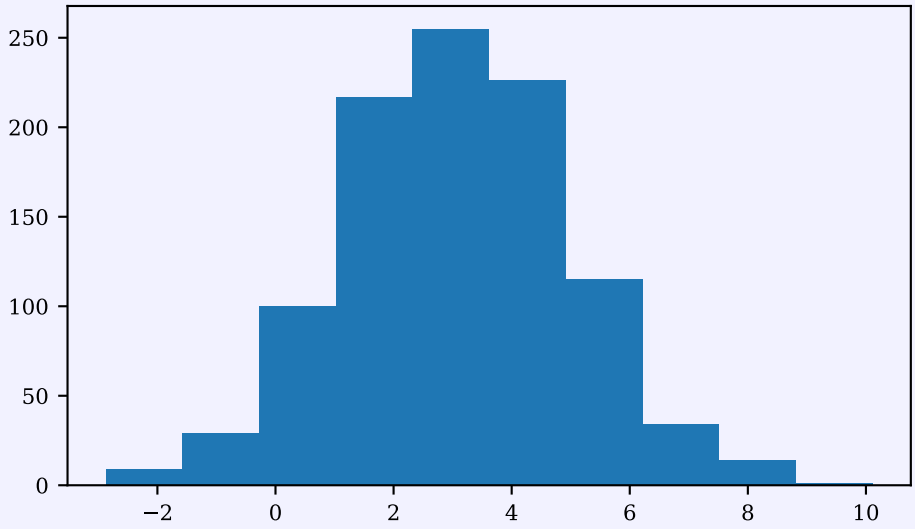


```
In [10]: i = np.random.uniform(low=-1, high=1, size=1000)
         plt.hist(i)
         plt.show()
```

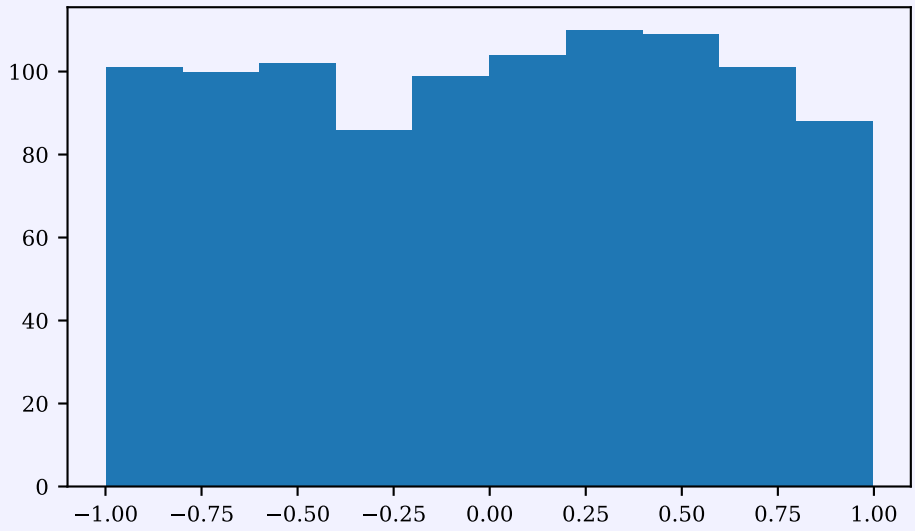

(2) Créer un échantillon de longeur 1000 suivant une loi exponentielle de paramètre 0.3. Tracer son histogramme.

Indexation

L'extraction d'éléments ou de sous-tableaux est très similaire à la syntaxe utilisée pour les listes Python. On utilise la notation « [] ».

```
In [11]: b
Out [11]: array([0, 1, 2, 3])
In [12]: b[2]                                    # On extrait le troisième élément
Out [12]: 2
```

```
In  [13]: b[1:2]                              # On sélectionne les indices 1 et 2
Out [13]: array([1])
In  [14]: b[1:]             # On coupe avant l'indice 1, on garde la partie droite
Out [14]: array([1, 2, 3])
In  [15]: b[:2]             # On coupe avant l'indice 2, on garde la partie gauche
Out [15]: array([0, 1])
In  [16]: b[:-1]     # On coupe avant le dernier indice, on garde la partie gauche
Out [16]: array([0, 1, 2])
```

Opérations élémentaires

Les tableaux Numpy sont utilisés pour du calcul numérique, on dispose donc des opérateurs suivants :

```
In  [17]: a, d
Out [17]: (array([1, 2, 3]), array([1., 1., 1.]))
In  [18]: a + d
Out [18]: array([2., 3., 4.])
In  [19]: a - d
Out [19]: array([0., 1., 2.])
In  [20]: a * a
Out [20]: array([1, 4, 9])
In  [21]: a / a
Out [21]: array([1., 1., 1.])
In  [22]: 3 * a
Out [22]: array([3, 6, 9])
In  [23]: a + 10
Out [23]: array([11, 12, 13])
```

Opérateurs d'agrégation

```
In  [24]: a
Out [24]: array([1, 2, 3])
In  [25]: a.sum()
Out [25]: 6
In  [26]: a.mean()
Out [26]: 2.0
In  [27]: a.min()
Out [27]: 1
In  [28]: a.max()
Out [28]: 3
In  [29]: a.std()
Out [29]: 0.816496580927726
In  [30]: a.var()
Out [30]: 0.6666666666666666
```

(3) Recalculer `a.mean()` et `a.std()` en utilisant des opérations élémentaires et des opérateurs d'agrégation plus simples. Pour utiliser la fonction racine carrée, il faut la rendre disponible avec l'instruction suivante :

```
from math import sqrt
```

Tableaux multidimensionnels

Plus généralement, on peut créer des tableaux avec un nombre quelconque de dimensions.

Création

Des tableaux multidimensionnels peuvent être créés à partir d'une liste de listes, (de listes,...).

```
In  [31]: a = np.array([[4, 5, 6], [7, 8, 9]])
```

On peut également spécifier les dimensions et la valeur d'initialisation.

```
In  [32]: b = np.zeros((3, 4, 2))
          c = np.ones((3, 4))
          d = np.full((2, 3), 3)
```

Il existe également

```
In  [33]: np.random.normal(loc=0, scale=1, size=(2, 3))
Out [33]: array([[-0.82824544, -0.13609548, -0.51752851],
                 [ 1.32973951,  1.43341784,  0.12911216]])
In  [34]: n = np.random.multivariate_normal(mean=[0, 2], cov=[[2, 1], [1, 2]],
          ↪  size=100)
          plt.scatter(n[:, 0], n[:, 1])
          plt.show()
```

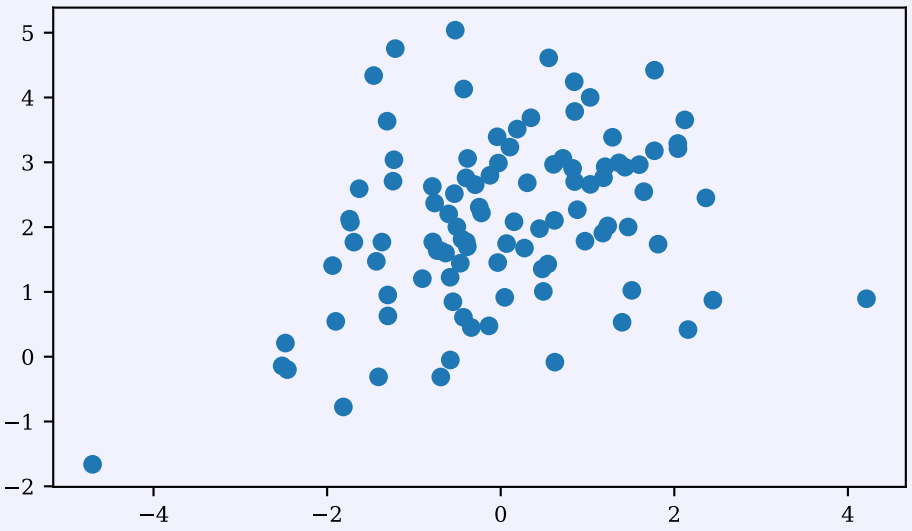

Pour les tableaux bidimensionnels (les matrices), il existe des fonctions issues de l'algèbre linéaire.

```
In  [35]: e = np.diag([1, 0, 1])          # Matrice diagonale de diagonale fixée
          f = np.eye(3)                   # Matrice identité d'ordre 3
```

Une fois créés, on peut calculer la taille des tableaux ou le nombre de dimensions

```
In  [36]: a.shape, a.ndim, b.shape, b.ndim
Out [36]: ((2, 3), 2, (3, 4, 2), 3)
```

(4) Que donne la fonction longueur `len` lorsqu'on l'applique sur un tableau ?

(5) Créer les tableaux suivants :

$$A_1 = \begin{pmatrix} 1 \\ -1 \\ 0 \end{pmatrix}, \qquad A_2 = \begin{pmatrix} -3 & -2 & 1 \end{pmatrix}, \qquad A_3 = \begin{pmatrix} 0 & -2 & -2 \\ -2 & 0 & -2 \\ -2 & -2 & 0 \end{pmatrix}.$$

Transformations

Les tableaux peuvent être combinés entre eux de plusieurs manières.

Restructuration avec `reshape` On peut tout d'abord changer la structure d'un tableau.

```
In  [37]: a.reshape((3, 2))
Out [37]: array([[4, 5],
                 [6, 7],
                 [8, 9]])
In  [38]: a.reshape((6, 1))
Out [38]: array([[4],
                 [5],
                 [6],
                 [7],
                 [8],
                 [9]])
```

(6) Utiliser la fonction `reshape` pour créer les matrices suivantes

$$A_1 = \begin{pmatrix} 1 & 2 & 3 & 4 \\ 5 & 6 & 7 & 8 \end{pmatrix}, \qquad A_2 = \begin{pmatrix} 1 & 3 & 5 & 7 \\ 2 & 4 & 6 & 8 \end{pmatrix}$$

Ajout de fausse dimension Il est souvent utile d'ajouter une fausse dimension à un tableau existant. L'exemple le plus courant est lorsqu'il s'agit de considérer un tableau unidimensionnel en une matrice ligne ou colonne.

```
In  [39]: a = np.array([1, 2, 3])
          a.shape; a.ndim
Out [39]: (3,)
          1
```

On ajoute ensuite une fausse dimension avec l'instruction `np.newaxis` :

```
In  [40]: b = a[np.newaxis, :]
          b.ndim; b.shape
Out [40]: 2
          (1, 3)
In  [41]: c = a[:, np.newaxis]
          c.ndim; c.shape
Out [41]: 2
          (3, 1)
```

L'opération inverse est possible avec la fonction `squeeze`.

```
In  [42]: b.squeeze()
Out [42]: array([1, 2, 3])
In  [43]: c.squeeze()
Out [43]: array([1, 2, 3])
```

(7) Écrire une fonction qui transforme une matrice colonne en une matrice ligne.

Concaténation avec `np.concatenate` Il s'agit de « coller » deux tableaux selon une dimension. Les tableaux doivent avoir le *même nombre de dimensions*.

```
In  [44]: a = np.array([1, 2, 3])
          b = np.array([4, 5, 6])
          np.concatenate((a, b))
Out [44]: array([1, 2, 3, 4, 5, 6])
```

Lorsque les tableaux ont plusieurs dimensions, il faut indiquer sur quelle dimension on souhaite concaténer via l'argument `axis`. Par défaut, la concaténation se fait selon la première dimension. On peut concaténer selon la dernière dimension en spécifiant `axis=-1`.

```
In  [45]: a = np.array([[1, 2, 3], [4, 5, 6]])
          b = np.array([[7, 8, 9], [10, 11, 12]])
          np.concatenate((a, b), axis=0)
Out [45]: array([[ 1,  2,  3],
                 [ 4,  5,  6],
                 [ 7,  8,  9],
                 [10, 11, 12]])
In  [46]: np.concatenate((a, b))
Out [46]: array([[ 1,  2,  3],
                 [ 4,  5,  6],
                 [ 7,  8,  9],
                 [10, 11, 12]])
In  [47]: np.concatenate((a, b), axis=1)
Out [47]: array([[ 1,  2,  3,  7,  8,  9],
                 [ 4,  5,  6, 10, 11, 12]])
In  [48]: np.concatenate((a, b), axis=-1)
Out [48]: array([[ 1,  2,  3,  7,  8,  9],
                 [ 4,  5,  6, 10, 11, 12]])
```

(8) Soient A_1 et A_2 deux matrices carrées. Écrire une fonction qui renvoie la matrice suivante

$$\begin{pmatrix} A_1 & -A_2 \\ A_2 & A_1 \end{pmatrix}.$$

(9) Soit A une matrice et v un vecteur colonne et λ un scalaire. Écrire une fonction qui renvoie la matrice suivante

$$\begin{pmatrix} A & v \\ v^T & \lambda \end{pmatrix}.$$

(10) Écrire une fonction qui prend en argument la première ligne de la matrice circulante suivante

$$C = \begin{pmatrix} c_0 & c_1 & c_2 & \dots & c_{n-1} \\ c_{n-1} & c_0 & c_1 & & c_{n-2} \\ c_{n-2} & c_{n-1} & c_0 & & c_{n-3} \\ \vdots & & & \ddots & \vdots \\ c_1 & c_2 & c_3 & \dots & c_0 \end{pmatrix},$$

et renvoie cette matrice. On pourra commencer par générer la matrice C sans sa dernière colonne, la fonction `np.tile` pourra être utile.

Empilement avec `np.stack` Lorsqu'on souhaite « empiler » des tableaux, on ajoute une nouvelle dimension. Il faut alors utiliser la fonction `np.stack`.

```
In  [49]: a = np.array([1, 2])
          b = np.array([3, 4])
          np.stack((a, b))
```

```
Out [49]: array([[1, 2],
                 [3, 4]])
```

```
In  [50]: a = np.diag([1, 2, 3])
          b = np.diag([4, 5, 6])
          c = np.stack((a, b))
          c
Out [50]: array([[[1, 0, 0],
                  [0, 2, 0],
                  [0, 0, 3]],

                 [[4, 0, 0],
                  [0, 5, 0],
                  [0, 0, 6]]])
In  [51]: c.shape
Out [51]: (2, 3, 3)
```

Par défaut la dimension rajoutée est en première position. L'argument `axis` permer de changer ce comportement. La valeur -1 veut dire la dernière dimension.

```
In  [52]: c = np.stack((a, b), axis=-1)
          c
Out [52]: array([[[1, 4],
                  [0, 0],
                  [0, 0]],

                 [[0, 0],
                  [2, 5],
                  [0, 0]],

                 [[0, 0],
                  [0, 0],
                  [3, 6]]])
In  [53]: c.shape
Out [53]: (3, 3, 2)
In  [54]: d = np.stack((a, b), axis=1)
          d
Out [54]: array([[[1, 0, 0],
                  [4, 0, 0]],

                 [[0, 2, 0],
                  [0, 5, 0]],

                 [[0, 0, 3],
                  [0, 0, 6]]])
In  [55]: d.shape
Out [55]: (3, 2, 3)
```

Opérations algébriques

Lorsque les tableaux sont unidimensionnels, on peut calculer le produit scalaire.

```
In  [56]: a = np.array([1, 2, 3]); b = np.array([4, 5, 6])
          np.dot(a, b)
Out [56]: 32
```

Pour des tableaux bidimensionnels

```
In  [57]: c = np.array([[1, 2], [3, 4]])
          d = np.array([[0, 1], [1, 0]])
          np.matmul(c, d)
Out [57]: array([[2, 1],
                 [4, 3]])
In  [58]: np.transpose(c)
Out [58]: array([[1, 3],
                 [2, 4]])
In  [59]: d.transpose()
Out [59]: array([[0, 1],
                 [1, 0]])
In  [60]: d.T
Out [60]: array([[0, 1],
                 [1, 0]])
In  [61]: c ** 2                                    # Produit case-à-case !
Out [61]: array([[ 1,  4],
                 [ 9, 16]])
```

(11) Écrire une fonction permettant de créer une matrice A de taille $n \times p$ telle que $A_{ij} = 1/(ij)$. On remarquera que si u et v sont deux vecteurs de taille n et p alors uv^T est une matrice de taille $n \times p$ telle que $\left[uv^T\right]_{ij} = u_i v_j$

```
def matrix(n, p):
    # Définir la fonction ici
```

2 Découverte de Pandas

Pandas est une bibliothèque Python qui permet de manipuler et analyser des structures de données.

Pour commencer, il faut charger la bibliothèque **Pandas** avec l'instruction suivante.

```
In  [62]: import pandas as pd
```

Une convention largement utilisée est d'importer **Pandas** sous le raccourci **pd**. Toutes les fonctionnalités de **Pandas** seront donc accessibles à travers ce raccourci.

2.1 Structure de données Pandas

2.1.1 Les séries

La première structure de données fournie par **Pandas** est une collection d'objets de même type appelée une *série*.

Création On peut les définir à partir d'une liste Python ou d'un tableau unidimensionnel **NumPy** :

```
In  [63]: a = pd.Series([1, 2, 3])
          b = pd.Series(["foo", "bar", "baz"])
          c = np.array([1, 2, 3])
          d = pd.Series(c)
```

Si jamais on souhaite convertir une série en un tableau unidimensionnel **NumPy** :

```
In  [64]: a = pd.Series([1, 2, 3])
          a.to_numpy()
Out [64]: array([1, 2, 3])
```

On peut donner un nom à la série

```
In  [65]: b = pd.Series(["foo", "bar", "baz"], name="Nom")
```

L'index Une différence majeure avec un tableau unidimensionnel est qu'une série `Pandas` dispose d'un *index* : une collection d'étiquettes qui repère chaque élément de la série. Lorsque ces étiquettes ne sont pas fournies, `Pandas` utilise les nombres entiers à partir de zéro.

```
In  [66]: pd.Series(["foo", "bar", "baz"])
Out [66]: 0    foo
          1    bar
          2    baz
          dtype: object
```

Pour fournir cet index, il suffit d'utiliser l'argument `index`.

```
In  [67]: age = pd.Series(
              [23, 24, 24, 25],
              index=["Agathe", "Béatrice", "Cédric", "Donna"]
          )
          age
Out [67]: Agathe      23
          Béatrice    24
          Cédric      24
          Donna       25
          dtype: int64
```

Pour retourner à l'index par défaut (avec des entiers à partir de 0), on utilise

```
In  [68]: age.reset_index(drop=True)
Out [68]: 0    23
          1    24
          2    24
          3    25
          dtype: int64
```

Pour changer l'index, on affecte simplement l'attribut `index`.

```
In  [69]: age.index = ["Ag", "Bé", "Cé", "Do"]
          age
Out [69]: Ag    23
          Bé    24
          Cé    24
          Do    25
          dtype: int64
```

Accès On peut accéder aux éléments d'une série de deux manières différentes :

1. Grâce aux étiquettes formant l'index. On utilise alors la méthode `loc`.
2. En utilisant la position absolue des éléments dans la série. On utilise alors la méthode `iloc`.

```
In  [70]: a = pd.Series(["Un", "Deux", "Trois"], index=[1, 2, 3])
          a.loc[1]
```

```
Out [70]: 'Un'
In  [71]: a.iloc[1]
Out [71]: 'Deux'
```

En utilisant `loc` ou `iloc`, on peut extraire de plusieurs manières :

```
In  [72]: age = pd.Series(
              [23, 24, 24, 25],
              index=["Agathe", "Béatrice", "Cédric", "Donna"],
              name="Age"
          )
```

— Directement en donnant un élément de l'index pour extraire l'élément correspondant

```
In  [73]: age.loc["Agathe"]
Out [73]: 23
In  [74]: age.loc["Cédric"]
Out [74]: 24
In  [75]: age.iloc[0]
Out [75]: 23
In  [76]: age.iloc[-1]
Out [76]: 25
```

— En fournissant une liste d'éléments de l'index pour extraire une sous-série

```
In  [77]: age.loc[["Agathe", "Donna"]]
Out [77]: Agathe    23
          Donna     25
          Name: Age, dtype: int64
In  [78]: age.iloc[[1, 3]]
Out [78]: Béatrice    24
          Donna       25
          Name: Age, dtype: int64
```

— En utilisant la notation *slice*

```
In  [79]: age.iloc[:-1]
Out [79]: Agathe      23
          Béatrice    24
          Cédric      24
          Name: Age, dtype: int64
In  [80]: age.iloc[2:]
Out [80]: Cédric    24
          Donna     25
          Name: Age, dtype: int64
In  [81]: age.loc["Cédric":]
Out [81]: Cédric    24
          Donna     25
          Name: Age, dtype: int64
In  [82]: age.loc["Béatrice":"Donna"]
Out [82]: Béatrice    24
          Cédric      24
          Donna       25
          Name: Age, dtype: int64
In  [83]: age.loc["Agathe":"Donna":2]
Out [83]: Agathe    23
          Cédric    24
          Name: Age, dtype: int64
```

— En fournissant un masque : un tableau de booléen de même taille que la série.

```
In  [84]: masque = [True, False, False, True]
          age.loc[masque]
Out [84]: Agathe    23
          Donna     25
          Name: Age, dtype: int64
```

Le masque peut également être une série de booléens de même index.

```
In  [85]: masque = pd.Series([True, False, False, True])
          masque.index = age.index
          masque
Out [85]: Agathe       True
          Béatrice    False
          Cédric      False
          Donna        True
          dtype: bool
In  [86]: age.loc[masque]
Out [86]: Agathe    23
          Donna     25
          Name: Age, dtype: int64
```

À noter que les masques sont rarement fournis directement sous forme d'un tableau ou d'une série de booléens. Ils sont plutôt construit directement à partir d'une autre série voire de la série elle-même.

```
In  [87]: masque = age > 23
          masque
Out [87]: Agathe      False
          Béatrice     True
          Cédric       True
          Donna        True
          Name: Age, dtype: bool
In  [88]: age.loc[masque]
Out [88]: Béatrice    24
          Cédric      24
          Donna       25
          Name: Age, dtype: int64
```

(12) Charger la série avec la commande suivante.

```
s1 = pd.read_csv("data/s1.csv", index_col=0, squeeze=True)
```

Construire les séries suivantes :
- La liste des prénoms donnés plus de 100000 fois
- L'effectif total des prénoms précédant `SACHA`

2.1.2 Les *DataFrame*

La structure de données la plus utilisée est le tableau individu–variable. `Pandas` les modélise avec la classe `pd.DataFrame`. Il s'agit d'une collection d'objets de type `pd.Series` représentant les colonnes d'un tableau individu–variable.

Création On peut construire des *DataFrame* de plusieurs manières :
- en fournissant un dictionnaire dont les clés sont les noms des caractéristiques et les valeurs sont des listes Python, des tableaux unidimensionnels `NumPy` ou des séries `Pandas` représentant les caractéristiques.

```
In  [89]: col1 = np.array([23, 24, 24, 25])
          col2 = ["Agathe", "Béatrice", "Cédric", "Donna"]
          pd.DataFrame({
            "Age": col1,
            "Nom": col2
          })
Out [89]:    Age       Nom
          0   23    Agathe
          1   24  Béatrice
          2   24    Cédric
          3   25     Donna
In  [90]: age = pd.Series([23, 24, 24, 25])
          nom = pd.Series(["Agathe", "Béatrice", "Cédric", "Donna"])
          pd.DataFrame({
            "Age": age,
            "Nom": nom
          })
Out [90]:    Age       Nom
          0   23    Agathe
          1   24  Béatrice
          2   24    Cédric
          3   25     Donna
```

Attention, l'index de chaque série est utilisé pour construire un index commun

```
In  [91]: age = pd.Series([23, 24, 24, 25], index=[0, 1, 2, 3])
          nom = pd.Series(["Agathe", "Béatrice", "Cédric", "Donna"],
          ↪  index=[2, 3, 4, 5])
          pd.DataFrame({
            "Age": age,
            "Nom": nom
          })
Out [91]:    Age       Nom
          0  23.0       NaN
          1  24.0       NaN
          2  24.0    Agathe
          3  25.0  Béatrice
          4   NaN    Cédric
          5   NaN     Donna
```

— à partir d'un fichier `csv` qu'on charge à l'aide la fonction `pd.read_csv`.

```
In  [92]: pd.read_csv("data/s1.csv")
Out [92]:    preusuel  nombre
          0      LUCAS  117001
          1       EMMA  105209
          2       ENZO   97980
          3        LÉA   96491
          4       HUGO   91960
          ..       ...     ...
          995   KELIAN    1984
          996      JAD    1983
          997   THELMA    1982
          998  MANELLE    1981
          999    KESSY    1972

          [1000 rows x 2 columns]
```

Pour convertir un *DataFrame* en un tableau bidimensionnel `NumPy`, on peut faire appel à la fonction

`to_numpy()` :

```
In  [93]: col1 = np.array([23, 24, 24, 25])
          col2 = ["Agathe", "Béatrice", "Cédric", "Donna"]
          df = pd.DataFrame({
            "Age": col1,
            "Nom": col2
          })
          df.to_numpy()
Out [93]: array([[23, 'Agathe'],
                 [24, 'Béatrice'],
                 [24, 'Cédric'],
                 [25, 'Donna']], dtype=object)
```

Attention cependant au type utilisé pour le tableau `NumPy`, ici `object` pour tous les éléments.

Informations utiles

```
In  [94]: col1 = np.array([23, 24, 24, 25])
          col2 = ["Agathe", "Béatrice", "Cédric", "Donna"]
          df = pd.DataFrame({
            "Age": col1,
            "Nom": col2
          })
          df.columns
Out [94]: Index(['Age', 'Nom'], dtype='object')
In  [95]: df.shape
Out [95]: (4, 2)
In  [96]: len(df)
Out [96]: 4
In  [97]: df.dtypes
Out [97]: Age     int64
          Nom    object
          dtype: object
```

La plupart des informations ci-dessus sont synthétisées lors de l'appel à `info()`

```
In  [98]: df.info()
Out [98]: <class 'pandas.core.frame.DataFrame'>
          RangeIndex: 4 entries, 0 to 3
          Data columns (total 2 columns):
          Age    4 non-null int64
          Nom    4 non-null object
          dtypes: int64(1), object(1)
          memory usage: 192.0+ bytes
```

L'index Les *DataFrame* dispose également d'un index commun à toutes les colonnes pour repérer tout individu (une ligne) dans le tableaux individus-variables.

On peut changer l'index à partir d'une colonne existante.

```
In  [99]: df
Out [99]:    Age       Nom
          0   23    Agathe
          1   24  Béatrice
          2   24    Cédric
          3   25     Donna
```

```
In  [100]: df.set_index("Nom")
Out [100]:           Age
          Nom
          Agathe      23
          Béatrice    24
          Cédric      24
          Donna       25
```

Accès On peut extraire les colonnes sous forme de séries de plusieurs manières :

— Si le nom de colonne est un nom d'attribut valide (pas d'espace ou caractères spéciaux...)

```
In  [101]: df.Age
Out [101]: 0    23
           1    24
           2    24
           3    25
           Name: Age, dtype: int64
```

— De manière plus générale

```
In  [102]: df["Age"]
Out [102]: 0    23
           1    24
           2    24
           3    25
           Name: Age, dtype: int64
```

Pour extraire plusieurs colonnes, il suffit de donner la liste

```
In  [103]: df[["Age", "Nom"]]
Out [103]:    Age       Nom
          0    23    Agathe
          1    24  Béatrice
          2    24    Cédric
          3    25     Donna
```

Pour extraire des enregistrements (lignes), on utilise `loc` et `iloc`

```
In  [104]: df.loc[df.Age >= 24]
Out [104]:    Age       Nom
          1    24  Béatrice
          2    24    Cédric
          3    25     Donna
In  [105]: df.iloc[[2, 3]]
Out [105]:    Age     Nom
          2    24  Cédric
          3    25   Donna
```

On peut également combiner les deux types d'extraction

```
In  [106]: df.loc[df.Age >= 24, ["Age"]]
Out [106]:    Age
          1    24
          2    24
          3    25
```

Modification Ajout/suppression de colonnes

```
In  [107]: df.drop(columns=["Age"])
Out [107]:         Nom
           0    Agathe
           1  Béatrice
           2    Cédric
           3     Donna
```